原著論文 Original Paper

ニューラルネットワークを用いた雑談対話からのユーザの興味推定

Estimating User Interest from Chat Dialogue using Neural Networks

稲葉 通将 Michimasa Inaba
広島市立大学大学院情報科学研究科
Graduate School of Information Sciences, Hiroshima City University
ianba@hiroshima-cu.ac.jp

高橋 健一 Kenichi Takahashi
(同 上)
takahasi@hiroshima-cu.ac.jp

keywords: Interest Estimation, Personalization, Chat Dialogue, Dialogue System

Summary

Non-task-oriented dialogue systems are required to chat with users in accordance with their interests. In this study, we propose a neural network-based method for estimating speakers' levels of interest from dialogues. Our model first converts given utterances into utterance vectors using a word sequence encoder with word attention. Afterward, our novel attention approach, sentence-specific sentence attention extracts useful information for estimating the level of interest. Additionally, we introduce a new pre-training method for our model. Experimental results indicated that it was most effective to use topic-specific sentence attention and proposed pre-training in combination.

1. ま え が き

人と人とのコミュニケーションにおいて雑談は重要であり，人の会話の約 62%は雑談であるという報告もある [Koiso 16]．雑談は人とコンピュータの会話においても重要であり，人とのオープンドメインな雑談の実現を目指した雑談対話システムに関する研究が近年活発に行われている [Higashinaka 14, Ritter 11, Sordoni 15, Vinyals 15, Zhao 17]．雑談対話システムの研究開発において，対話のパーソナライズは重要な課題の一つである．ユーザの経験やユーザの好みに応じた対話を行うことができれば，ユーザの満足度は大きく向上することが期待できる．対話のパーソナライズを目指した研究としては，雑談対話ログからエンティティ間の関係 [Bang 15] やエンティティと述語項構造 [Hirano 15] を獲得する研究があるが，これらは，過去のユーザの発話を用いてシステム発話を生成することによるパーソナライズの実現を目指したものである．

一方，本研究ではユーザの興味に基づくシステムのパーソナライズを目的とし，トピック（例えば音楽，ファッション，健康など）に対するユーザの興味の度合いを推定する．これにより，システムはユーザが興味のないトピックを避け，興味があるトピックについて対話をすることが可能になり，ユーザのエンゲージメント・満足度の向上が期待できる．

そこで本研究では，雑談対話中の発話を入力とし，話者の興味を推定するニューラルネットワークベースの手法を提案する．なお，本手法では対話中に出現したトピックだけではなく，それ以外のトピックに関しても同時に推定を行う．これは，たとえユーザが興味を持つトピックであっても，延々と同じトピックについて話せばユーザは飽きてしまう危険性があるためである．対話中に直接出てきていないトピックに対しても興味の有無が推定できれば，ユーザが飽きないうちに話を次のトピックに展開させることが可能となる．

本研究でニューラルネットワークを用いる理由として，性質の異なるデータを 1 つのモデルで統一的に扱うことが可能という利点があることが挙げられる．例えば，ニューラルネットワークを用いた対話に関する研究では，Twitter や映画字幕などの大量に入手可能なデータを用いてまずモデルを事前学習し，その後比較的少量の対話データで学習する方法が有効であったとする報告が複数存在する [Li 16, Serban 16, Zhang 18]．そこで本研究においても，大量の対話以外のデータを用いた事前学習を行うことで，より高い性能を達成するためニューラルネットワークを用いる．

なお，現在の対話システムの性能は十分ではなく，自然な対話を行うことが困難であることから，本研究では人間同士の対話を対象とする．また，対話システムの発話に依存しない興味推定を実現するため，本研究では対話相手の発話は利用せず，興味推定対象の話者の発話のみを興味推定のために用いる．

2. 関 連 研 究

テキストデータからのユーザの興味推定に関する研究では，SNS，特に Twitter を対象とした研究が活発に行われている．例えば Chen らは対象となるユーザのツイート，およびそのユーザのフォロワーのツイートに含まれる単語による bag-of-words を用いて興味をモデリングする手法を提案した [Chen 10]．また，知識ベースから獲得した単語の上位概念を用いる手法もいくつか提案されている．例えば，Abel らは OpenCalais*1 を用いて取得した人名 (Person), イベント名 (Events), 音楽グループ名 (Music groups) といった固有表現の出現頻度により Twitter ユーザのモデリングを行った [Abel 11]．その他にも単語の上位概念を用いる同様の手法として，Wikipedia のカテゴリーを用いた手法 [Kapanipathi 14, Michelson 10, Zarrinkalam 15]，DBPedia を用いた手法 [Kapanipathi 11] などが提案されている．また，LDA などのトピックモデルを用いた手法もいくつか提案されている [Bhattacharya 14, Han 16, Weng 10]．以上の手法はユーザは自分が興味のあることのみを投稿している，という前提に基づいている．この前提は，ユーザが常に主体的に発信する SNS であれば問題ない．しかし，対話では人は必ずしも興味のあることについてのみ発話するとは限らない．対話では，ユーザが現在の話題にそれほど興味がなくても，相手に話を合わせ対話を継続することはそれほど珍しいことではないため，これらの手法を直接適用することが難しい．後述する実験では，これらの SNS を対象とした興味推定手法の 1 つを比較手法として用い，対話への適用が困難であることを示す．

対話からのユーザの興味を推定する研究としては，ユーザの興味レベル (Level-of-Interest: LOI) の推定に関する研究が知られている．Schuller らは，ある製品に関して紹介する話者とその聞き手の二者間の対話において，聞き手側の製品に対する興味を推定するというタスクを対象とし，音響的素性と言語的素性を用いた SVM により 3 段階で興味を推定した [Schuller 06]．また，2010 年には INTERSPEECH Paralinguistic Challenge のサブチャレンジとして LOI 推定タスクが設定された [Schuller 10]．同じタスクを対象とした研究として，Wang らの研究もある [Wang 13]．ただし，これらの研究では興味を推定する対象はその対話中で話される話題 1 つに決められており，オープンドメインではない．また，対話内容もビジネス会話であり，雑談を対象としたものでもない．

3. 興 味 推 定 手 法

本研究で対象とするタスクは，話者 s が他の話者との対話中に行った発話集合 $U_s = (u_1, u_2, ..., u_n)$ が与えられ，興味推定対象のトピック $T = (t_1, t_2, ..., t_m)$ に対応する話者 s の興味度 $Y_s = (y_1, y_2, ..., y_m)$ を推定することにある．t_i はそれぞれ具体的なトピック，例えば映画や旅行などに対応する．また，y_i は各トピックに対する話者の興味の度合いを意味する値であり，前節で述べた LOI 推定の研究に合わせ 3 段階とした．すなわち，$y_i = 0$ は「興味なし」を，$y_i = 1$ は「少し興味あり」を，$y_i = 2$ は「興味あり」を意味する．

*1 http://www.opencalais.com/

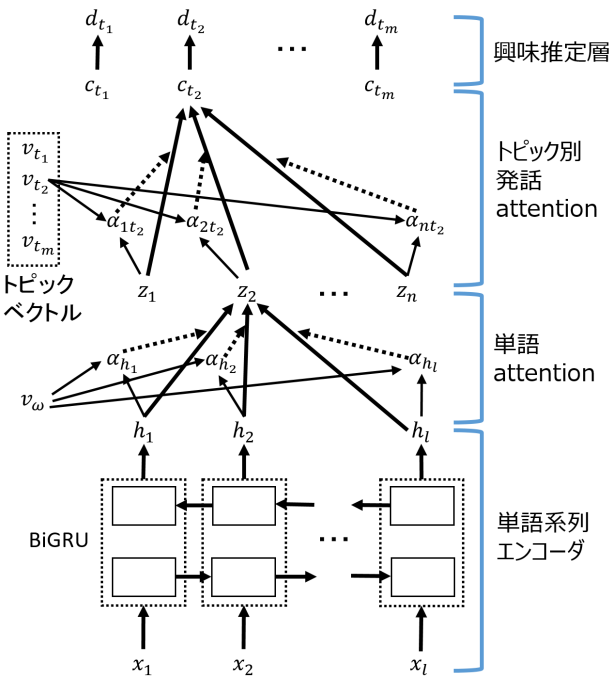

図 1 提案手法の概要

発話から興味の推定を行うには，以下の 2 点の情報を抽出することが重要である．

- その発話はどのようなトピックに関するものであるか
- 話者はそのトピックについてどの程度興味を持っているか

そのために本研究では，以上 2 点を効率的に行うためのニューラルネットワークモデル，および本モデルの効率的な学習を行うための事前学習手法を提案する．提案モデルの概要を図 1 に示す．図に示したように，提案モデルは単語系列エンコーダ, 単語 attention, トピック別発話 attention, 興味推定層の 4 つが順に処理を行い，興味推定を行う．なお，今回提案する事前学習手法は単語系列エンコーダに対して適用する．以下ではそれぞれの詳細について説明する．

3·1 単語系列エンコーダ

単語系列エンコーダは発話，すなわち単語の系列を Recurrent Neural Network(RNN) を用いてエンコードする．最初に，発話中の単語は Word2Vec[Mikolov 13] によりベクトルに変換され，単語ベクトルの系列 $x = (x_1, x_2, ..., x_l)$ を得る．本研究では RNN の中間層に Bidirectional-GRU (BiGRU) を用いる．BiGRU は系列を x_1 から x_l の順に

読み込む順方向 GRU ($\overrightarrow{GRU}$) と x_l から x_1 の順に読み込む逆方向 GRU ($\overleftarrow{GRU}$) からなり，順方向 GRU において，時刻 i における隠れ状態 $\overrightarrow{h_i}$ は以下の式により得られる．

$$\overrightarrow{h_i} = \overrightarrow{GRU}(x_i, \overrightarrow{h_{i-1}}) \tag{1}$$

backward GRU についても $\overleftarrow{h_i}$ を同じく計算する．目的となる隠れ状態 h_i は順方向 GRU と逆方向 GRU にそれぞれ x_i を入力した際の出力を用いて以下の式により求められる．

$$h_i = [\overrightarrow{h_i} : \overleftarrow{h_i}] \tag{2}$$

ここで [:] はベクトルの連結を意味する．

3·2 トピック分類事前学習

ユーザがどのトピックにどれだけ興味を持つかを推定するためには，まず各発話がどのトピックに関するものかを推定する必要がある．すべての発話に人手でアノテーションすることも可能だが，その作業コストは極めて高い．一方，トピックの情報が明示的に与えられない場合，モデルは発話集合とそのユーザの興味度から間接的にトピックを推定する必要があるため，適切な学習は困難である．そこで本モデルでは単語系列エンコーダに対し，事前学習 [Erhan 10] の考え方を導入する．本モデルの事前学習では，発話中のトピックをより効率的に推定するため，単語系列エンコーダに対し，文のトピック分類を行う学習を実施する．ここで重要な点は，分類クラスを本研究が対象とする興味推定対象トピック T と同一にすることである．このことにより，興味推定の学習時に発話とトピックの対応関係を推定するための学習難易度が下がり，適切な学習が可能となる．

事前学習時には入力文の最後の単語 x_l を BiGRU に入力した際の出力 h_l を用いて，入力文の各トピッククラスへの所属確率 p を以下の式により計算する (ここでは次節で述べる単語 attention は使用しない).

$$p = \mathrm{softmax}(W_c h_l + b_c) \tag{3}$$

式中の W_c と b_c は事前学習時にのみ使用されるトピック分類のためのパラメータである．事前学習時の損失関数にはクロスエントロピーを用いる．

3·3 単 語 attention

本モデルには [Yang 16] らが提案した単語 attention を導入する．単語 attention は,「全ての単語が求めたい結果に平等に貢献するわけではない」という考えに基づき, attention 機構により単語ごとに異なる重み付けを行ったエンコード結果を得るための手法である．例えば,「私は野球が好きです」という発話の意味を理解するためには「は」や「です」という単語よりも「野球」や「好き」という単語のほうが重要度が高いと考えられ，単語 attention は後者の単語により大きな重みを与える．

単語 attention よる発話エンコードベクトル z は以下の式により求められる．

$$v_{hi} = \tanh(W_\omega h_i + b_\omega) \tag{4}$$

$$\alpha_{hi} = \frac{\exp(v_{hi}^{\mathrm{T}} v_\omega)}{\sum_i \exp(v_{hi}^{\mathrm{T}} v_\omega)} \tag{5}$$

$$z = \sum_i \alpha_{hi} h_i \tag{6}$$

W_ω と b_ω はパラメータである．単語 attention はニューラル翻訳モデルやニューラル対話モデルのようなデコーダを用いて系列を生成する場合の (通常の)attention と異なり，各単語に対して共通の文脈ベクトル v_ω を α_i の計算に用いる．v_ω は単語の重要性を計算するためのパラメータであり，W_ω と b_ω と同様，学習時に最適化される．

3·4 トピック別発話 attention

単語系列エンコーダと単語 attention は，発話 $U_s = (u_1, u_2, ..., u_n)$ を発話ベクトル $Z_s = (z_1, z_2, ..., z_n)$ にエンコードする．次は，この発話ベクトルからユーザのトピックごとの興味推定のための情報を抽出する．

そのために本研究では，単語 attention と同じく，全ての発話が各トピックの興味度の推定に平等に貢献するわけではないという考え方に基づき，トピック別発話 attention を新たに提案する．なお，Yang らは単語 attention と同じ構造の文 attention[Yang 16] を提案しているが，文 attention では文の重要性を計算するためのパラメータは 1 つである (単語 attention における文脈ベクトル v_ω と同等のパラメータ)．しかし，発話の重要性はトピックごとに異なると考えられる．例えば,「私は毎朝ジョギングをしています」という発話からはスポーツや健康といったトピックの興味推定には役立つと考えられるが，ゲームや車・乗り物に対する興味推定にはおそらく有用ではない．

そこでトピック別発話 attention では，トピック t_i に対する発話の重要性を計算するためのトピックベクトル v_{t_i} を用いて，内容ベクトル c_{t_i} を以下の式により求める．

$$v_j = \tanh(W_r z_j + b_r) \tag{7}$$

$$\alpha_{jt_i} = \frac{\exp(v_j^{\mathrm{T}} v_{t_i})}{\sum_j \exp(v_j^{\mathrm{T}} v_{t_i})} \tag{8}$$

$$c_{t_i} = \sum_j \alpha_{jt_i} z_j \tag{9}$$

式中の W_r はトピックによらず共通で用いるパラメータである．また，トピックベクトル v_{t_i} は学習により最適化される．

3·5 興 味 推 定 層

トピック別発話 attention により得られた内容ベクトル c_{jt_i} を用いて，トピック t_i に対する興味度 d_{t_i} を以下の式により求める．

$$d_{t_i} = \tanh(W_{t_i} c_{t_i} + b_{t_i}) + 1 \tag{10}$$

表 1 使用したトピック

旅行	映画	音楽
アウトドア	学校	家電製品
芸能人・タレント	PC 関連	ビデオゲーム
動物・生き物	住まい	家事
家族・夫婦	結婚・恋愛	健康
美容	ファッション	料理・グルメ
スポーツ・運動	読書	車・乗り物
政治・経済・社会	アニメ・漫画	歴史

ここで，パラメータ W_{t_i} はトピック t_i の興味度推定のためのパラメータであり，対象トピックごとに異なるパラメータを学習する．最後の $+1$ は興味度 d_{t_i} を正解である y_i と同じ 0〜2 にスケーリングするための項である．

学習時の損失関数には下式に示すように，正解である y_i と d_{t_i} の平均二乗誤差を用いる．

$$L = \frac{1}{m}\sum_{i}^{m}(y_i - d_{t_i})^2 \tag{11}$$

4. 評 価 実 験

提案手法の評価のため実験を行った．本実験のため，2 名の被験者が 1 対 1 で対話したチャットログと各被験者が回答したアンケートを収集し，データセットを作成した．性能比較のため，ベースライン手法との比較も実施した．

4·1 データセット

初対面の被験者 2 名による日本語のテキストチャットデータと各被験者の興味に関するアンケートを収集した．被験者はクラウドワークス *2で募集した．各被験者には対話を行う前にアンケートに回答するよう依頼し，アンケートの内容は表 1 に示す 24 種類のトピックそれぞれに対して，自分の興味の度合いを「興味なし」,「少し興味あり」,「興味あり」の三者択一で選択させた．表 1 のトピックは [Hirano 15] と同じく， Yahoo!知恵袋 *3のカテゴリーをもとに，二者間の初対面の対話で取り上げられやすい話題を中心に設定した．

対話は 1 回 1 時間とし，Skype のインスタントメッセンジャーを介して行った．被験者に対しては「話の中で相手と自分の間で共通して興味のあることを見つけ，それについて話を膨らませていくことを心がけてください」とだけ教示し，話すべき内容・話題についての指示は行わなかった．表 2 に実際の対話例を示した．

収集した全てのチャットデータ中の発話を被験者別に分類し，1 被験者の行った全発話とその被験者のアンケートの結果のペアを 1 データとして扱う．データの統計情報を表 3 に示す．

*2 https://crowdworks.jp/
*3 https://chiebukuro.yahoo.co.jp/

表 2 対話例

A	対話を開始します。よろしくお願いします。
B	よろしくお願いします。
A	私は，旅行に行ったり，暇な時間にカフェ巡りしたりするのが好きです。趣味は何ですか？
B	私もよくカフェ巡りします。
A	古民家隠れ家風なオシャレカフェ見つけたら気分が上がりますよね。コーヒー派ですか？
B	わかります！私はカフェで甘いものを注文することが多いので、コーヒー派ですね。
A	私もです！ちょっと前はパンケーキでした。最近，パフェが人気らしいですね。どんなスイーツが好きですか？
B	私もパンケーキやケーキをよく食べます。パフェが流行ってるとは知りませんでした！パフェって大きくてなかなか完食できないイメージがあります。

表 3 使用データ

被験者数 (データ数)	163
対話数	408
発話数	49029
「興味あり」の平均トピック数	11.48
「少し興味あり」の平均トピック数	7.30
「興味なし」の平均トピック数	5.21

4·2 実 験 設 定

単語ベクトルの獲得には次元数 200，ウインドウサイズは 5，最小出現頻度は 10 とし，約 100GB の Twitter データで学習を行った Word2Vec[Mikolov 13] を用いた．

単語系列エンコーダの入力層の次元は 200，BiGRU の出力の次元は 400 とし，BiGRU は 1 層とした．また，各 attention 層は出入力ともに 400 次元，興味推定層の入力は 400 次元，出力は 1 次元とした．学習時には Adam[Kingma 15] で最適化を行った．

トピック分類の学習 (事前学習) には，Yahoo!知恵袋データ (第二版)*4を使用した．各トピックに対応する質問文，および回答文から，77 万文を学習データ，各トピック 100 文ずつの 2,400 文をテストデータとした．事前学習の結果，テストデータの正解率は 0.755 であった．

評価は 10 分割交差検証により行う．なお，対話単位ではなく，データ単位 (被験者単位) で交差検証を行うため，学習データとテストデータ間において，同一の被験者による発話が使用されることはない．

4·3 評 価 方 法

提案手法を対話システムの話題選択に用いることを想定した場合，対話システムがその時点で対応できる話題

*4 http://www.nii.ac.jp/dsc/idr/yahoo/chiebkr2/Y_chiebukuro.html

の中から，より望ましい話題を提案手法が選択するという活用法が有効であると考えられる．そこで，本実験では推定した興味度 d_{t_i} に基づいて各トピックを順位付けし，上位にユーザが興味を持つトピックを，下位に興味を持たないトピックを順位付けできる性能により評価を行う．順位付けの評価尺度として，情報検索の分野で広く使用されている指標である Normalized Discounted Cumulative Gain ($NDCG$) を用いる．$NDCG$ は 0 から 1 の値を取り，1 に近いほど正しい順位予測結果であることを意味する．$NDCG$ は以下の式により計算する．

$$NDCG@k = \frac{DCG_k}{IDCG_k} \tag{12}$$

$$DCG_k = rel_i + \sum_{i=2}^{K} \frac{rel_i}{log_2 i} \tag{13}$$

ここで，k は上位何位までを考慮するかを意味する．rel_i は i 位に順位付けされたターゲットに対する適合度を意味する値であり，本研究では各トピックに対するユーザ s の興味度 Y_s の値 (0, 1, 2) を適合度とする．$IDCG$ (Ideal DCG) は順位リストが適合度順に正しく並んだ場合の DCG である．

提案手法，および後述するニューラルネットワークベースの比較手法については，初期パラメータを変更した 5 回の 10 分割交差検証を実施し，$NDCG@1$ が最良の結果となったものを各手法の結果として採用する．なお，$NDCG@1$ をモデル選択の基準として用いるのは，$NDCG@1$ が大きな値であった場合，以降の k においても性能が高くなる傾向が観察されたためである．

また，各トピックに対するユーザの興味度を正しく推定できるかを評価するため，各手法が出力した興味度と正解との間の平均二乗誤差 (MSE:Mean Squared Error) によっても評価する．

4·4 比 較 手 法

提案手法の有効性の比較のため，提案手法の一部を変更した以下の 3 つの設定の実験を行う．

事前学習なし

提案した事前学習を行わず，単語系列エンコーダの初期値を乱数として学習を行う．その他の設定は提案手法と同一である．

トピック別発話 attention なし

トピック別発話 attention による内容ベクトルの獲得の代わりに，発話ベクトルの Max Pooling の結果を用いて内容ベクトルを獲得し，興味推定を行う．その他の設定は提案手法と同一である．

事前学習なし＆トピック別発話 attention なし

提案した事前学習を行わず，発話ベクトルの Max Pooling により内容ベクトルを獲得し，興味推定を行う．その他の設定は提案手法と同一である．

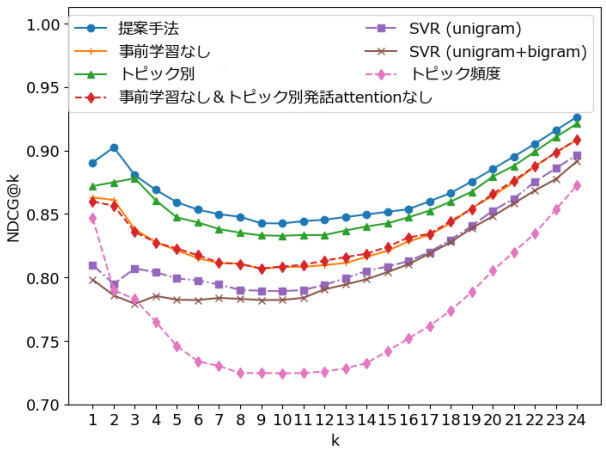

図 2 実験結果 (NDCG@k)

また，以下の 2 つのベースライン手法とも比較を行う．

トピック頻度

1 つ目のベースラインとして，Abel らの手法 [Abel 11] をもとにした興味推定手法を用いる．Abel らの手法は SNS ユーザの興味モデリング手法として提案されたものであり，OpenCalais*5を用いてユーザのツイートに含まれる単語の固有表現を取得し，その頻度ベクトルによりユーザの興味をモデル化した．ただし，本研究では日本語対話を対象としており，英語のみを扱える OpenCalais は利用できない．そこで 3·4 節で述べた事前学習で作成された文のトピック分類器を使用し，発話のトピックを推定する．推定したトピックの出現頻度をトピックへの興味とみなし，頻度順でトピックを順位付けする．

SVR

2 つ目のベースラインとして，Support Vector Regression (SVR) を用いてユーザの各トピックの興味度を推定する．素性は unigram と bigram を用い，unigram のみを用いた場合と両方を用いた場合で実験を行う．SVR モデルはトピックごとに個別に学習を行い，各トピックに対する興味度の推定を行う．SVR の実装としては scikit-learn[Pedregosa 11] を使用し，カーネルは RBF カーネルを用いる．SVR のハイパーパラメータについては，RBF カーネルの γ は scikit-learn におけるデフォルトの auto とし，コスト C は 0.01, 0.1, 1, 10, 100 の 5 つでそれぞれ学習を行い，$NDCG@1$ が最も高くなった結果を採用する．

4·5 実 験 結 果

実験結果を図 2 に示す．この図は $NDCG$ の計算に用いるトピック数 k を 1 から 24 まで変化させた場合の

*5 http://www.opencalais.com/

表 4 実験結果 (平均二乗誤差)

提案手法	**0.533**
事前学習なし	0.580
トピック別発話 attention なし	0.561
事前学習なし ＆ トピック別発話 attention なし	0.568
SVR (unigram)	0.622
SVR (unigram + bigram)	0.632

$NDCG$ の値を図示したものである．図より，提案手法が他の手法と比べ，すべての k において $NDCG$ が高いことがわかる．事前学習を適用した手法 (提案手法・トピック別発話 attention なし) と，適用していない手法 (事前学習なし・事前学習なし＆トピック別発話 attention なし) を比較すると，事前学習を適用した手法が大きく性能を伸ばしていることがわかる．ここから，提案した事前学習の有効性が確認できる．一方，トピック別発話 attention に着目すると，トピック別発話 attention を適用した事前学習なしと事前学習なし＆トピック別発話 attention なしの結果がほぼ同じであることがわかる．ただし，わずかな差ではあるが $k \geq 5$ において，事前学習なし＆トピック別発話 attention なしの方が $NDCG$ は大きい結果となっている．ここから，事前学習を行わずにトピック別発話 attention を使用することは性能の向上に寄与しないことがわかる．一方，事前学習とトピック別発話 attention を同時に適用した提案手法は，トピック別発話 attention なしと比べ性能が向上している．このことから，本研究で提案した事前学習とトピック別発話 attention は同時に適用することが重要であることが確認できた．これは，トピック分類事前学習を行うことで発話ベクトルにトピックの情報が埋め込まれるため，式 (8) のトピックベクトル v_{t_i} が効率的に学習可能になったためであると考えられる．

SVR に関しては，unigram と bigram を用いる場合よりも unigram を単独で用いた方が良い性能を示したものの，提案手法を含むニューラルネットワークベースの手法に劣る結果となった．トピック頻度ベースラインは $k = 1$ の場合は SVR 手法よりも高い $NDCG$ を示した．これは，ユーザが積極的に発言したトピックに関して，興味ありと正しく推定できたためである．一方，ニューラルネットワークベースの手法には劣る結果となり，$k \geq 4$ の場合，すべての手法の間で最低の $NDCG$ となった．このことは対話では話者は常に興味のあることのみを発言するわけではなく，対話相手に話を合わすため興味の小さいトピックに関しても発言していることが原因であると考えられる．

表 4 には，各手法が出力した興味度と正解との間の平均二乗誤差 (MSE) を示した（興味度を直接出力しないトピック頻度ベースラインを除く）．表より，提案手法の値が最も小さいことから，提案手法は適切な興味度の推定ができていることがわかる．一方で，ニューラルネットワークベースの手法のうち，事前学習なしが最も性能が低く，事前学習とトピック別発話 attention を同時に使用することの重要性がここからも確認できた．

4·6 考　　察

§1 トピック別発話 attention の可視化による分析

前節の実験結果より，トピック別発話 attention と提案した事前学習を同時に用いることが重要であることが確認された．そこで，このトピック別発話 attention について分析するため，式 (8) で求められる発話文の重み α_{jt_i} の値をトピック別に計算し，可視化したものを図 3，図 4 に示した．図 3 は事前学習を行った提案手法の結果であり，図 4 は事前学習なしの結果である．図は濃い色であればあるほど α_{jt_i} が高い値であることを意味する．

図 3 より，提案手法では文の意味に対応した発話文の重みが高い値になっていることがわかる．一方で，例えば図の (4) では,「野球」や「ルール」など，スポーツに関連する語が含まれているが,「スポーツ」に対応する発話の重みは大きくなっていない．これは，発話の重みは単に文中の単語のトピックに反応しているわけではなく，トピックに対するユーザの興味の度合いを反映している結果である．さらに，図の (6) でスマートフォンゲームのポケモン GO を話題としているにもかかわらず,「ゲーム」に対応する発話の重みは比較的小さい値である一方，スポーツが大きい値をとっている．ポケモン GO は普段ゲームをやらない人にも受け入れられており，そのことが反映されていると思われる．一方，(7) の家族やゲームなど，文とはあまり関係ないと考えられるトピックに関する重みが大きくなったものも存在した．

他方，事前学習なしの結果である図 4 を見ると，重みと発話文の意味がほとんど関連していないことがわかる，例えば，(5) の文は興味推定には重要ではなく，図 3 では全てのトピックの重みが小さな値となっている．一方で，図 4 では「動物・生き物」が比較的高い値となってしまっている．同様に (7)，(8) についても関連の薄いトピックの重みが大きな値を取っていることがわかる．

以上の結果から，トピック別発話 attention の学習には事前学習が重要であることが確認された．事前学習を行わない場合，発話とトピックの対応付けを 1 から行わなければならず，その困難さのため，適切な学習が難しいと考えられる．前節の実験結果より，事前学習により，その対応付けができるだけで大きく性能を向上させることが可能である．さらに，トピック別発話 attention が正しく学習・機能することで，提案手法は最も良い性能を示したと言える．

§2 学習データ量の分析

ニューラルネットワークモデルの学習において，学習データの量はモデルの性能を左右する非常に重要な要素の 1 つである．本研究では 163 名の被験者による 408 対

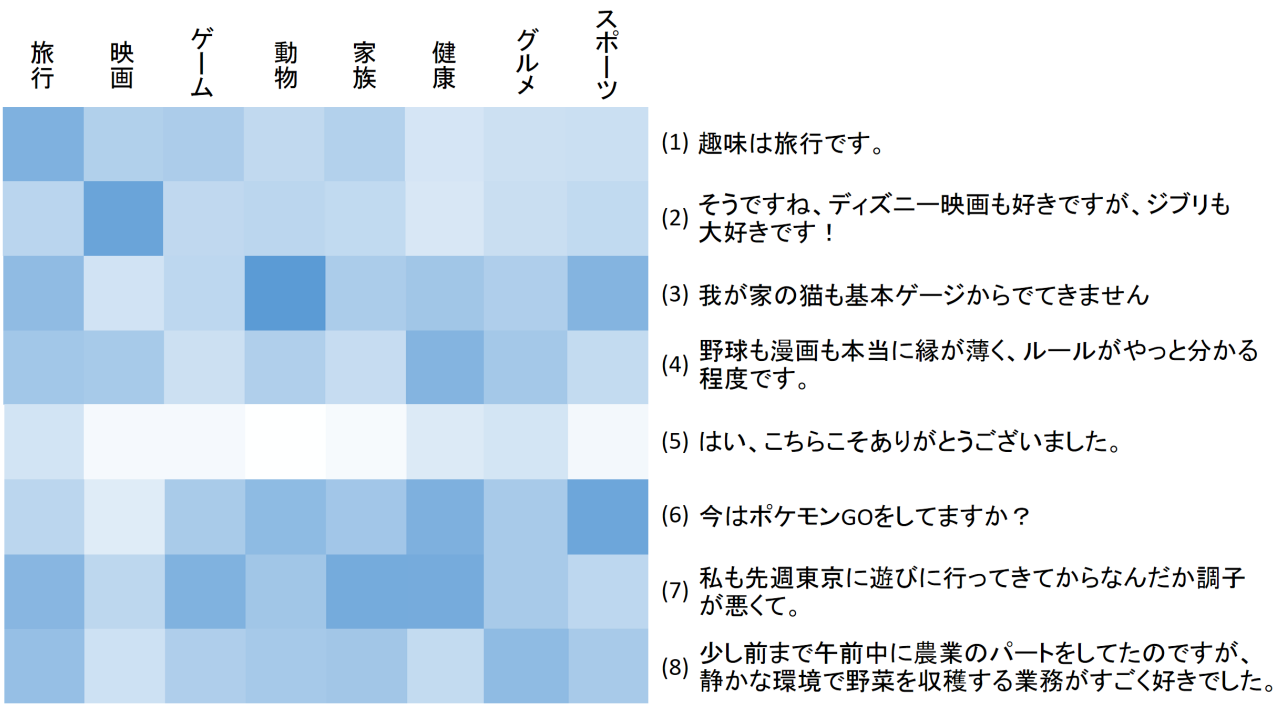

図 3 提案手法のトピック別発話 attention の可視化

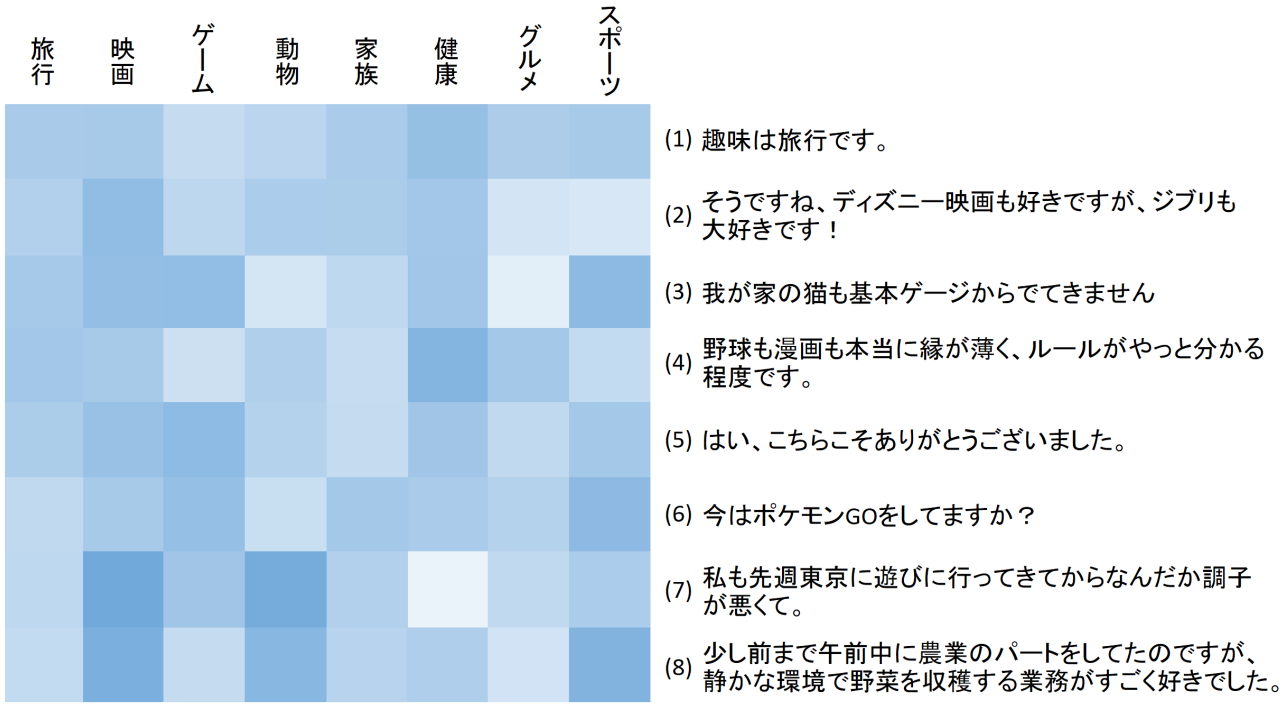

図 4 事前学習なしのトピック別発話 attention の可視化

話を収集したが，データ量としては必ずしも十分ではなく，学習データを追加することで性能をさらに向上させることが可能であると考えられる．そこで本節では，提案手法における学習データの量と性能の関係を分析する．特に，学習データを追加するにあたり，1 被験者あたりの発話数を増やすべきか，もしくは被験者の数を増やすべきかという収集方針の決定は，効率的なデータ収集のため重要であると思われる．

そのために，学習データとして用いる被験者数，および発話数を制限して 10 分割交差検証を行い，性能の変化を分析した．なお，10 分割交差検証の際のテストデータの被験者数・発話数は制限していない．

$NDCG@k$ の結果を図 5 に示す．図には学習に使用する被験者数を全体の 10%, 50%, 90%に制限した場合の結果と，1 被験者あたりの発話数を 10%, 50%, 90%に制限した場合の結果，および全データの結果 (図 2 の提案手法と同一) を示した．ここから，発話数を制限するよりも，被験者数を制限した場合のほうが大きく性能が低下して

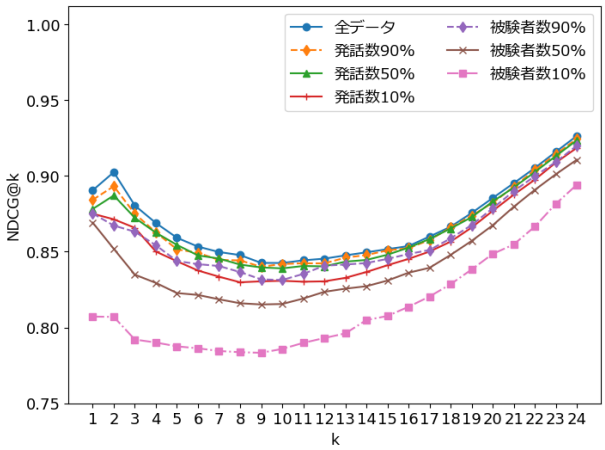

図 5 学習データ量を制限した場合の提案手法の性能評価 (NDCG@k)

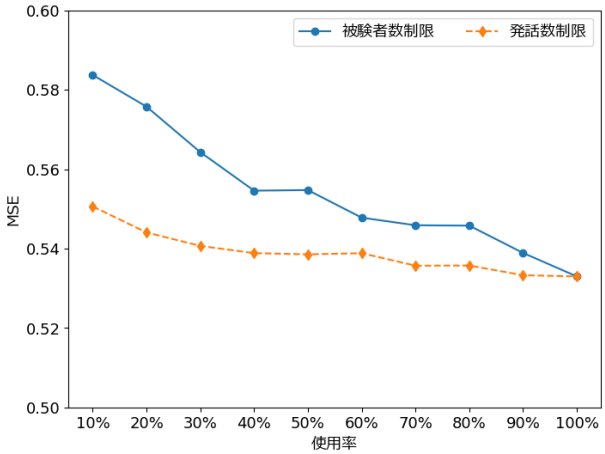

図 6 学習データ量を制限した場合の提案手法の性能評価 (MSE)

いることがわかる．特に，被験者数が 10%の $NDCG$ は著しく性能が低下している．一方で，発話数を制限した場合には，全データを使用した場合よりも性能は低下するが，その影響は比較的小さいことがわかる．

図 6 には被験者数，および発話数の学習データへの使用率を 10%から 100%まで 10%刻みで変化させた場合の平均二乗誤差の結果を示した．この結果からも $NDCG$ の結果と同様，発話数を制限するよりも，被験者数を制限した場合のほうが大きく性能が低下 (MSE が上昇) したことが確認できる．

以上の結果より，学習データを追加する場合，1 被験者あたりの発話数を増やすよりも，被験者数を増加させることが性能向上に寄与することが確認された．

5. む す び

本研究では，雑談対話におけるユーザの発話を入力とし，事前に設定したトピックに対するそのユーザの興味度を推定するニューラルネットワークベースの手法を提案した．提案手法はまず，BiGRU を用いた単語系列エンコーダと単語 attention により発話をエンコードし，発話ベクトル集合を得る．次に，この発話ベクトル集合からトピック別発話 attention を用いて，推定対象の各トピックに対応したベクトルを生成する．最後に，このベクトルから対応するトピックに対する話者の興味の度合いを推定する．学習時にはトピック分類を行う事前学習を実施することで単語系列エンコーダを学習し，その後，興味度推定の学習を行う．実験の結果，提案手法はベースライン手法と比べ，より適切にトピックに対する興味度を推定できることが確認された．また，提案したトピック別発話 attention とトピック分類事前学習を併用することが性能向上に有効であることが確認された．

今後は，提案手法を対話システムに適用し，ユーザと対話を行う予定である．ユーザが興味を持つトピックが推定できたとしても，具体的な発話をどのように生成するかはまた別の問題である．例えばスポーツに興味があるユーザは，すべての種類のスポーツに興味があるとは限らない．サッカーには興味があるがゴルフには興味がないといったことは十分考えられる．そのため，提案手法の有効な適用方法について検討していきたい．

謝 辞

本研究は JSPS 科研費 16H05880 の支援を受けて実施されたものである．

◇ 参 考 文 献 ◇

[Abel 11] Abel, F., Gao, Q., Houben, G.-J., and Tao, K.: Analyzing user modeling on twitter for personalized news recommendations, *User Modeling, Adaption and Personalization*, pp. 1–12 (2011)

[Bang 15] Bang, J., Noh, H., Kim, Y., and Lee, G. G.: Example-based chat-oriented dialogue system with personalized long-term memory, in *IEEE International Conference on Big Data and Smart Computing (BigComp)*, pp. 238–243 (2015)

[Bhattacharya 14] Bhattacharya, P., Zafar, M. B., Ganguly, N., Ghosh, S., and Gummadi, K. P.: Inferring user interests in the twitter social network, in *Proceedings of the 8th ACM Conference on Recommender Systems*, pp. 357–360 (2014)

[Chen 10] Chen, J., Nairn, R., Nelson, L., Bernstein, M., and Chi, E.: Short and tweet: Experiments on recommending content from information streams, in *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, pp. 1185–1194 (2010)

[Erhan 10] Erhan, D., Bengio, Y., Courville, A., Manzagol, P.-A., Vincent, P., and Bengio, S.: Why does unsupervised pre-training help deep learning?, *Journal of Machine Learning Research*, Vol. 11, No. Feb, pp. 625–660 (2010)

[Han 16] Han, J. and Lee, H.: Characterizing the interests of social media users: Refinement of a topic model for incorporating heterogeneous media, *Information Sciences*, Vol. 358, pp. 112–128 (2016)

[Higashinaka 14] Higashinaka, R., Imamura, K., Meguro, T., Miyazaki, C., Kobayashi, N., Sugiyama, H., Hirano, T., Makino, T., and Matsuo, Y.: Towards an open-domain conversational system fully based on natural language processing, in *Proceedings of the 25th International Conference on Computational Linguistics (COLING)*, pp. 928–939 (2014)

[Hirano 15] Hirano, T., Kobayashi, N., Higashinaka, R., Makino, T., and Matsuo, Y.: User information extraction for personalized dialogue systems, *The 19th Workshop on the Semantics and Pragmatics*

of Dialogue (SemDial), pp. 67–75 (2015)

[Kapanipathi 11] Kapanipathi, P., Orlandi, F., Sheth, A. P., and Passant, A.: Personalized filtering of the twitter stream, in *Proceedings of the Second International Conference on Semantic Personalized Information Management: Retrieval and Recommendation*, pp. 6–13 (2011)

[Kapanipathi 14] Kapanipathi, P., Jain, P., Venkataramani, C., and Sheth, A.: User interests identification on twitter using a hierarchical knowledge base, in *European Semantic Web Conference*, pp. 99–113 (2014)

[Kingma 15] Kingma, D. P. and Ba, J.: Adam: A method for stochastic optimization, in *Proceedings of the 3rd International Conference on Learning Representations* (2015)

[Koiso 16] Koiso, H., Tsuchiya, T., Watanabe, R., Yokomori, D., Aizawa, M., and Den, Y.: Survey of conversational behavior: towards the design of a balanced corpus of everyday Japanese conversation, in *Proceedings of the 10th edition of the Language Resources and Evaluation (LREC)* (2016)

[Li 16] Li, J., Galley, M., Brockett, C., Spithourakis, G., Gao, J., and Dolan, B.: A persona-based neural conversation model, in *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, pp. 994–1003 (2016)

[Michelson 10] Michelson, M. and Macskassy, S. A.: Discovering users' topics of interest on twitter: A first look, in *Proceedings of the 4th Workshop on Analytics for Noisy Unstructured Text Data*, pp. 73–80 (2010)

[Mikolov 13] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., and Dean, J.: Distributed representations of words and phrases and their compositionality, in *Proceedings of the 27th Conference on Neural Information Processing Systems (NIPS)*, pp. 3111–3119 (2013)

[Pedregosa 11] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., et al.: Scikit-learn: Machine learning in Python, *Journal of Machine Learning Research*, Vol. 12, No. Oct, pp. 2825–2830 (2011)

[Ritter 11] Ritter, A., Cherry, C., and Dolan, W. B.: Data-driven response generation in social media, in *Proceedings of the 2011 Conference on Empirical Methods in Natural Language Processing*, pp. 583–593 (2011)

[Schuller 06] Schuller, B. W., Köhler, N., Müller, R., and Rigoll, G.: Recognition of interest in human conversational speech, in *Proceedings of the 9th Annual Conference of the International Speech Communication Association (INTERSPEECH)* (2006)

[Schuller 10] Schuller, B., Steidl, S., Batliner, A., Burkhardt, F., Devillers, L., Müller, C., and Narayanan, S.: The INTERSPEECH 2010 paralinguistic challenge, in *Proceedings of the 11th Annual Conference of the International Speech Communication Association (INTERSPEECH)*, pp. 2794–2797 (2010)

[Serban 16] Serban, I. V., Sordoni, A., Bengio, Y., Courville, A. C., and Pineau, J.: Building End-To-End Dialogue Systems Using Generative Hierarchical Neural Network Models, in *Proceedings of the 30th AAAI Conference on Artificial Intelligence*, Vol. 16, pp. 3776–3784 (2016)

[Sordoni 15] Sordoni, A., Galley, M., Auli, M., Brockett, C., Ji, Y., Mitchell, M., Nie, J.-Y., Gao, J., and Dolan, B.: A Neural network approach to context-sensitive generation of conversational responses, in *Proceedings of the 2015 Conference of the North American Chapter of the Association for Computational Linguistics Human Language Technologies (NAACL-HLT)* (2015)

[Vinyals 15] Vinyals, O. and Le, Q.: A neural conversational model, in *Proceedings of the ICML Deep Learning Workshop*, pp. 1–7 (2015)

[Wang 13] Wang, W. Y., Biadsy, F., Rosenberg, A., and Hirschberg, J.: Automatic detection of speaker state: Lexical, prosodic, and phonetic approaches to level-of-interest and intoxication classification, *Computer Speech & Language*, Vol. 27, No. 1, pp. 168–189 (2013)

[Weng 10] Weng, J., Lim, E.-P., Jiang, J., and He, Q.: Twitterrank: finding topic-sensitive influential twitterers, in *Proceedings of the 3rd ACM International Conference on Web Search and Data Mining*, pp. 261–270 (2010)

[Yang 16] Yang, Z., Yang, D., Dyer, C., He, X., Smola, A. J., and Hovy, E. H.: Hierarchical attention networks for document classification, in *Proceedings of the 15th Annual Conference of the North American Chapter of the Association for Computational Linguistics - Human Language Technologies (NAACL-HLT)*, pp. 1480–1489 (2016)

[Zarrinkalam 15] Zarrinkalam, F., Fani, H., Bagheri, E., Kahani, M., and Du, W.: Semantics-enabled user interest detection from twitter, in *Proceedings of the 2015 IEEE/WIC/ACM International Conference on Web Intelligence*, Vol. 1, pp. 469–476 (2015)

[Zhang 18] Zhang, S., Dinan, E., Urbanek, J., Szlam, A., Kiela, D., and Weston, J.: Personalizing Dialogue Agents: I have a dog, do you have pets too?, in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 2204–2213 (2018)

[Zhao 17] Zhao, T., Zhao, R., and Eskenazi, M.: Learning Discourse-level Diversity for Neural Dialog Models using Conditional Variational Autoencoders, in *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 654–664 (2017)

〔担当委員：岡田 将吾〕

2018 年 9 月 28 日　受理

著　者　紹　介

稲葉　通将（正会員）

平成 24 年 名古屋大学大学院情報科学研究科博士後期課程修了，同年広島市立大学大学院情報科学研究科助教，現在に至る．対話システム，対話処理に関する研究に従事．(博士 (情報科学))．電子情報通信学会，情報処理学会，IEEE 各会員．

高橋　健一（正会員）

昭和 52 年名古屋工業大学情報工学科卒業．昭和 54 年同大学大学院工学研究科修士課程終了．同年同大学工学部助手．同大学講師，助教授を経て，平成 6 年広島市立大学情報科学部教授．現在に至る．工学博士．主に機械学習，パターン情報処理の研究に従事．電子情報通信学会，IEEE 各会員