BERTを用いたマイクロブログユーザの興味推定に関する研究

中川嵩将　　上田芳弘　　坂本一磨
公立小松大学　生産システム部

2022年度 情報処理学会全国大会

2024年 12月 2日

新村柊月

はじめに

ユーザの「興味」は需要を反映する重要な要素としてマーケティングなどに活用できる。本研究では、ソーシャルメディアの投稿テキストからユーザの興味を推定する手法を提案する。

BERTを活用し、ソーシャルメディア投稿のテキストを分類することで、ユーザの興味推定に適用可能な手法を開発することを目的としている。

研究概要

1. テキストデータの整理
2. ファインチューニング
3. カテゴリ推定

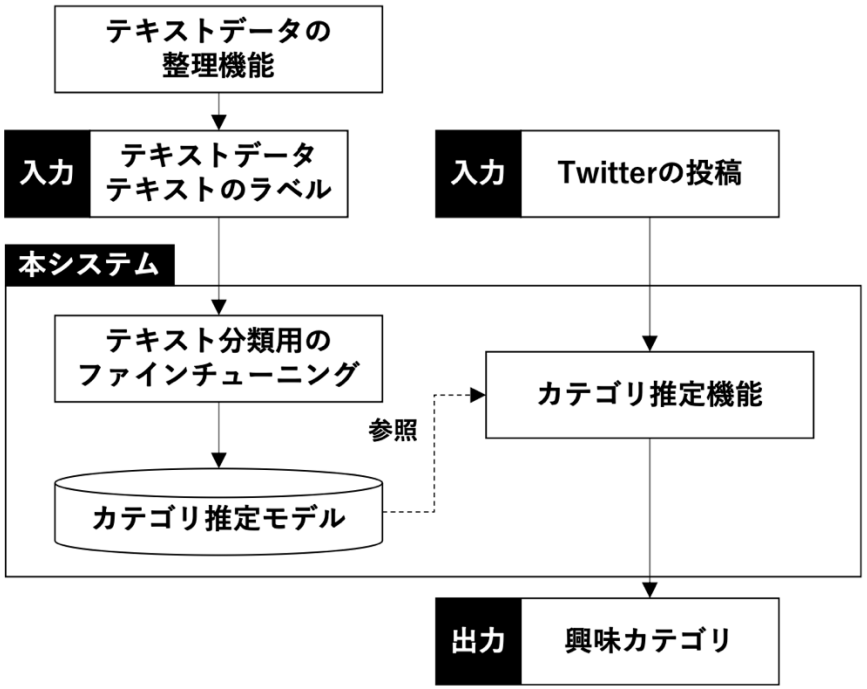

図１　システム概要

テキストデータの整理

- ファインチューニングのためのラベル付きテキストデータの作成

- ネットニュースからWebスクレイピングし、下記の構成で保存
  1行目：記事のタイト
  2行目：記事のURL
  3行目：記事の本文

- ネットニュースの6カテゴリに絞ってラベル付け
  国内、国際、経済、エンタメ、スポーツ、地域

ファインチューニング

- 日本語のWikipedia記事を学習した事前学習済みのBERTを使用

カテゴリ推定

- 構築したテキスト分類モデルにTwitterの投稿を分類させ、投稿者の興味を推定
- 2021 12/15~12/21 に収集したYahoo!ニュースを使用
- 記事数は479件
  - 学習データ： 6 割
  - 検証データ： 3 割
  - テストデータ： 1 割
- Twitterの投稿は10人の投稿から100件ずつ無作為に抽出

結果と考察

- 縦軸に損失の値、横軸に処理したミニバッチの数を示す
- テストデータの分類精度は約８割
- 薄い線が実際の出力、濃い線がスムージング後の出力
- 学習データは使用記事数が少ないため、損失が高いと考えられる。

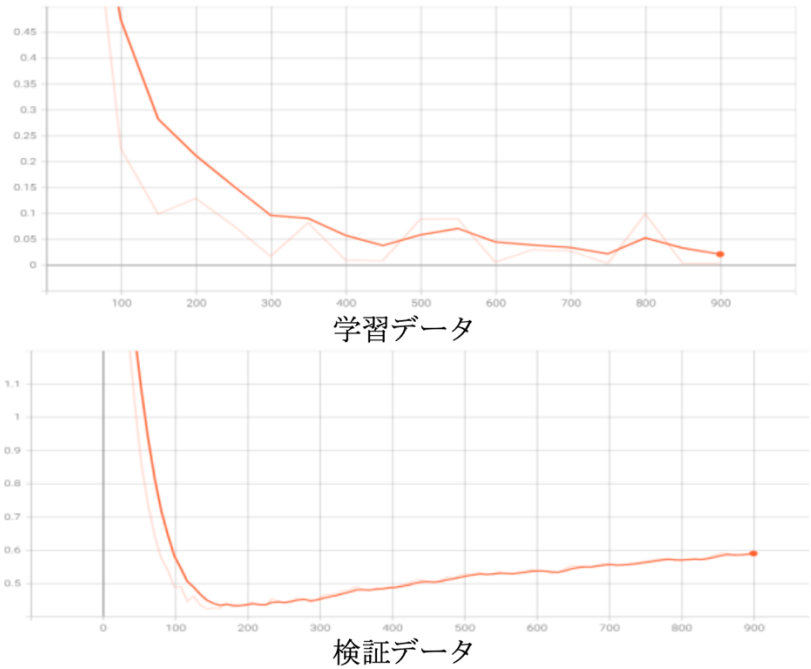

図2　学習時のデータに対する損失

結果と考察

- エンタメには日常会話や食事音楽などが含まれるためカテゴリを分ける必要がある
- スポーツは特徴があるため、精度が高い。
- 約９割で一つのカテゴリは一致
- 学習データやカテゴリを増やし、興味推定の評価の検討を進めていく

表１　興味推定の結果

		カテゴリ					
		国内	国際	経済	エンタメ	スポーツ	地域
投稿者	A	4	2	4	60	0	30
	B	33	1	10	40	0	16
	C	12	1	3	80	0	4
	D	13	2	3	64	1	17
	E	15	2	12	62	3	6
	F	16	10	1	66	0	7
	G	6	1	3	66	0	24
	H	13	0	4	58	0	25
	I	24	1	19	26	2	28
	J	15	1	5	47	1	31

表２　興味分類

		カテゴリ	
		推定結果	人
投稿者	A	エンタメ・地域	エンタメ・地域
	B	エンタメ・国内	エンタメ・経済
	C	エンタメ・国内	エンタメ・国内
	D	エンタメ・地域	エンタメ・地域
	E	エンタメ・国内	エンタメ・スポーツ
	F	エンタメ・国内	エンタメ・国内
	G	エンタメ・地域	エンタメ・国内
	H	エンタメ・地域	エンタメ・地域
	I	エンタメ・地域	国内・地域
	J	エンタメ・地域	エンタメ・国内

自身の考察

- 手法や概要は一般的な分類タスクである。
- 投稿文のような短い文に対しても有効である。
- 興味分類における興味抽出の過程は期待抽出にも応用できそうである。
- 期待として抽出するデータは決まっているが、どんな期待が抽出しにくいのかを定めるためにもアスペクトベースの期待抽出を検討する必要がある可能性があるかも。
- 手法としては似たものになるが、どうやって精度を上げていけるのか